Proyecto de Clasificación Multiclase: Estimación de Niveles de Obesidad

Este proyecto surge en el marco de la salud preventiva, utilizando el Machine Learning para clasificar niveles de obesidad basados en hábitos alimenticios y condición física.

El objetivo principal es desarrollar un modelo capaz de predecir con precisión una de las 7 categorías de peso (desde Peso Insuficiente hasta Obesidad Tipo III). Este es un problema de clasificación multiclase donde buscaremos no solo la precisión global, sino un equilibrio en las métricas por clase y un overfitting controlado inferior al 5%.

Variables Demográficas y Físicas:

Gender (Género): Género del encuestado (Masculino / Femenino).

Age (Edad): Edad del encuestado en años.

Height (Altura): Altura en metros.

Weight (Peso): Peso en kilogramos.

Hábitos Alimenticios:

family_history_with_overweight: ¿Tiene algún familiar que sufra o haya sufrido de sobrepeso? (Sí / No).

FAVC: ¿Consume alimentos ricos en calorías con frecuencia? (Sí / No).

FCVC (Consumo de vegetales): ¿Suele comer verduras en sus comidas? (1: Nunca, 2: A veces, 3: Siempre).

NCP (Número de comidas principales): ¿Cuántas comidas principales realiza al día? (Entre 1 y 4).

CAEC (Consumo de alimentos entre comidas): ¿Come algo entre horas? (No, A veces, Frecuentemente, Siempre).

CH2O (Consumo de agua): Cantidad de agua que bebe diariamente (1: Menos de un litro, 2: Entre 1 y 2 litros, 3: Más de 2 litros).

Hábitos de Estilo de Vida y Condición Física:

SMOKE: ¿Fuma? (Sí / No).

SCC (Monitoreo de calorías): ¿Lleva un control de las calorías que consume diariamente? (Sí / No).

FAF (Frecuencia de actividad física): ¿Con qué frecuencia realiza actividad física? (0: No realiza, 1: 1 a 2 días, 2: 2 a 4 días, 3: 4 a 5 días).

TUE (Tiempo de uso de tecnología): Tiempo de uso de dispositivos tecnológicos (móvil, ordenador, TV) al día. (0: 0-2 horas, 1: 3-5 horas, 2: Más de 5 horas).

CALC (Consumo de alcohol): ¿Con qué frecuencia consume alcohol? (No, A veces, Frecuentemente, Siempre).

MTRANS (Medio de transporte): ¿Qué transporte utiliza habitualmente? (Automóvil, Moto, Bicicleta, Transporte Público, Caminar).

Variable Objetivo (Target):

NObeyesdad (Nivel de Obesidad): Clasificación del individuo (Peso insuficiente, Peso normal, Sobrepeso I, Sobrepeso II, Obesidad I, Obesidad II y Obesidad III).

In [1]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import os

sns.set(style="whitegrid")
```

In [2]:
```
data = pd.read_csv("../data/raw/ObesityDataSet.csv")
df = data.copy()
```

In [3]:
```
print(f"El dataset contiene {df.shape[0]} registros y {df.shape[1]} columnas.")
df.head(10)
```

```
El dataset contiene 2111 registros y 17 columnas.
```

Out[3]:

	Gender	Age	Height	Weight	family_history_with_overweight	FAVC	FCVC	NCP	
0	Female	21.0	1.62	64.0	yes	no	2.0	3.0	S
1	Female	21.0	1.52	56.0	yes	no	3.0	3.0	S
2	Male	23.0	1.80	77.0	yes	no	2.0	3.0	S
3	Male	27.0	1.80	87.0	no	no	3.0	3.0	S
4	Male	22.0	1.78	89.8	no	no	2.0	1.0	S
5	Male	29.0	1.62	53.0	no	yes	2.0	3.0	S
6	Female	23.0	1.50	55.0	yes	yes	3.0	3.0	S
7	Male	22.0	1.64	53.0	no	no	2.0	3.0	S
8	Male	24.0	1.78	64.0	yes	yes	3.0	3.0	S
9	Male	22.0	1.72	68.0	yes	yes	2.0	3.0	S

In [4]:
```
df.shape
```

Out[4]: (2111, 17)

In [5]:
```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 2111 entries, 0 to 2110
Data columns (total 17 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   Gender                          2111 non-null   str
 1   Age                             2111 non-null   float64
 2   Height                          2111 non-null   float64
 3   Weight                          2111 non-null   float64
 4   family_history_with_overweight  2111 non-null   str
 5   FAVC                            2111 non-null   str
 6   FCVC                            2111 non-null   float64
 7   NCP                             2111 non-null   float64
 8   CAEC                            2111 non-null   str
 9   SMOKE                           2111 non-null   str
 10  CH2O                            2111 non-null   float64
 11  SCC                             2111 non-null   str
 12  FAF                             2111 non-null   float64
 13  TUE                             2111 non-null   float64
 14  CALC                            2111 non-null   str
 15  MTRANS                          2111 non-null   str
 16  NObeyesdad                      2111 non-null   str
dtypes: float64(8), str(9)
memory usage: 280.5 KB
```

In [6]:
```
print(df.isnull().sum())
print(f"\nNúmero de filas duplicadas: {df.duplicated().sum()}")
```

```
Gender                            0
Age                               0
Height                            0
Weight                            0
family_history_with_overweight    0
FAVC                              0
FCVC                              0
NCP                               0
CAEC                              0
SMOKE                             0
CH2O                              0
SCC                               0
FAF                               0
TUE                               0
CALC                              0
MTRANS                            0
NObeyesdad                        0
dtype: int64

Número de filas duplicadas: 24
```

In [7]:
```
# Filtramos el dataframe para ver solo las filas que tienen duplicados
duplicados_df = df[df.duplicated(keep=False)]

# Ordenamos por alguna columna (ej: Age) para ver las copias juntas
duplicados_df.sort_values(by='Age').head(10)
```

Out[7]:

	Gender	Age	Height	Weight	family_history_with_overweight	FAVC	FCVC	NCP
309	Female	16.0	1.66	58.0	no	no	2.0	1.0
295	Female	16.0	1.66	58.0	no	no	2.0	1.0
282	Female	18.0	1.62	55.0	yes	yes	2.0	3.0
443	Male	18.0	1.72	53.0	yes	yes	2.0	3.0
460	Female	18.0	1.62	55.0	yes	yes	2.0	3.0
496	Male	18.0	1.72	53.0	yes	yes	2.0	3.0
174	Male	21.0	1.62	70.0	no	yes	2.0	1.0
97	Female	21.0	1.52	42.0	no	no	3.0	1.0
145	Male	21.0	1.62	70.0	no	yes	2.0	1.0
179	Male	21.0	1.62	70.0	no	yes	2.0	1.0

Se ha identificado la presencia de 24 registros duplicados en el conjunto de datos original. Tras un análisis visual de estas filas, se ha tomado la decisión estratégica de eliminarlas basándonos en los siguientes pilares de ciencia de datos:

Prevención de Fuga de Datos (Data Leakage): Al trabajar con modelos de Machine Learning, es crítico asegurar que el modelo no "memorice" ejemplos exactos. Si un registro duplicado aparece tanto en el conjunto de entrenamiento como en el de prueba, las métricas de evaluación (como el Accuracy) serían artificialmente altas y poco realistas.

Mitigación de Sesgos por Datos Sintéticos: Dado que este dataset contiene datos generados mediante algoritmos para equilibrar las clases, la repetición exacta de registros con múltiples decimales sugiere redundancia técnica más que variabilidad biológica real.

Control del Overfitting: Eliminar estas redundancias es el primer paso para cumplir con el requisito del proyecto de mantener un overfitting inferior al 5%, obligando al modelo a aprender patrones generales de salud en lugar de casos específicos repetidos.

In [8]:
```
df.drop_duplicates(inplace=True)
print(f"Dimensiones después de eliminar duplicados: {df.shape}")
```

```
Dimensiones después de eliminar duplicados: (2087, 17)
```

In [9]:
```
# Estadísticas para Edad, Peso, Altura, etc.
df.describe().T
```

Out[9]:

	count	mean	std	min	25%	50%	75%	max
Age	2087.0	24.353090	6.368801	14.00	19.915937	22.847618	26.000000	61.00
Height	2087.0	1.702674	0.093186	1.45	1.630178	1.701584	1.769491	1.98
Weight	2087.0	86.858730	26.190847	39.00	66.000000	83.101100	108.015907	173.00
FCVC	2087.0	2.421466	0.534737	1.00	2.000000	2.396265	3.000000	3.00
NCP	2087.0	2.701179	0.764614	1.00	2.697467	3.000000	3.000000	4.00
CH2O	2087.0	2.004749	0.608284	1.00	1.590922	2.000000	2.466193	3.00
FAF	2087.0	1.012812	0.853475	0.00	0.124505	1.000000	1.678102	3.00
TUE	2087.0	0.663035	0.608153	0.00	0.000000	0.630866	1.000000	2.00

In [10]:

```
# Estadísticas para Género, Historial Familiar, Fumador, etc.
df.describe(include=['object']).T
```

```
C:\Users\gemit\AppData\Local\Temp\ipykernel_9572\985510633.py:2: Pandas4Warning:
For backward compatibility, 'str' dtypes are included by select_dtypes when 'obje
ct' dtype is specified. This behavior is deprecated and will be removed in a futu
re version. Explicitly pass 'str' to `include` to select them, or to `exclude` to
remove them and silence this warning.
See https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-mig
ration-select-dtypes for details on how to write code that works with pandas 2 an
d 3.
  df.describe(include=['object']).T
```

Out[10]:

	count	unique	top	freq
Gender	2087	2	Male	1052
family_history_with_overweight	2087	2	yes	1722
FAVC	2087	2	yes	1844
CAEC	2087	4	Sometimes	1761
SMOKE	2087	2	no	2043
SCC	2087	2	no	1991
CALC	2087	4	Sometimes	1380
MTRANS	2087	5	Public_Transportation	1558
NObeyesdad	2087	7	Obesity_Type_I	351

Análisis del Target: Balance de Clases

Para evitar que el modelo tenga sesgos, es vital comprobar si tenemos suficientes ejemplos de cada nivel de obesidad.

In [11]:

```
plt.figure(figsize=(10, 5))
sns.countplot(x='NObeyesdad', data=df, palette='viridis', order=df['NObeyesdad']
plt.title('Distribución de Clases (NObeyesdad)')
```

```
plt.xticks(rotation=45)
plt.show()

print("Frecuencia de clases:\n", df['NObeyesdad'].value_counts(normalize=True) *
```

```
C:\Users\gemit\AppData\Local\Temp\ipykernel_9572\763601157.py:2: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v
0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effe
ct.

  sns.countplot(x='NObeyesdad', data=df, palette='viridis', order=df['NObeyesda
d'].value_counts().index)
```

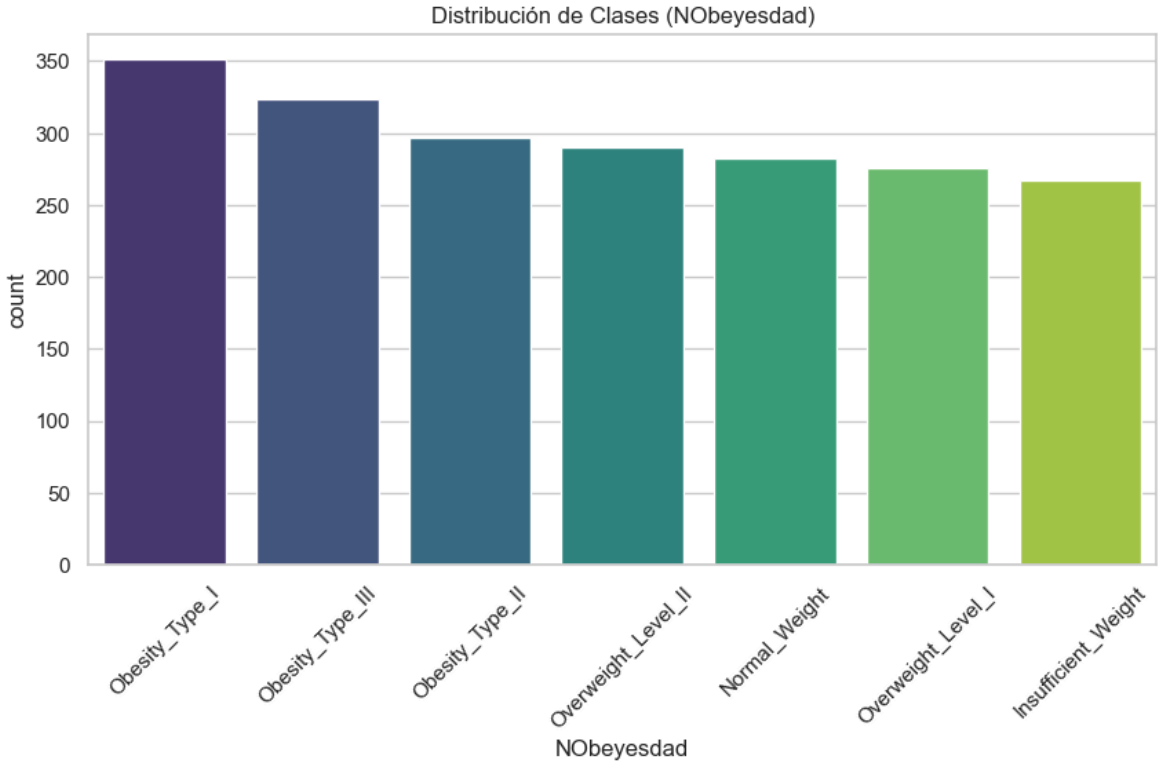


```
Frecuencia de clases:
 NObeyesdad
Obesity_Type_I         16.818400
Obesity_Type_III       15.524677
Obesity_Type_II        14.230954
Overweight_Level_II    13.895544
Normal_Weight          13.512218
Overweight_Level_I     13.224724
Insufficient_Weight    12.793483
Name: proportion, dtype: float64
```

El análisis de frecuencia de la variable objetivo **NObeyesdad** muestra una distribución equilibrada entre las 7 categorías. Esto garantiza que el modelo de clasificación multiclase no presente sesgos hacia una categoría específica y permite una evaluación de métricas más robusta.

In [12]:
```
plt.figure(figsize=(14, 7))
sns.boxplot(data=df, x='NObeyesdad', y='Weight', palette='magma')
plt.title('Distribución de Peso por Nivel de Obesidad')
plt.xticks(rotation=45)
plt.show()
```

```
C:\Users\gemit\AppData\Local\Temp\ipykernel_9572\587712667.py:2: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v
0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effe
ct.

  sns.boxplot(data=df, x='NObeyesdad', y='Weight', palette='magma')
```

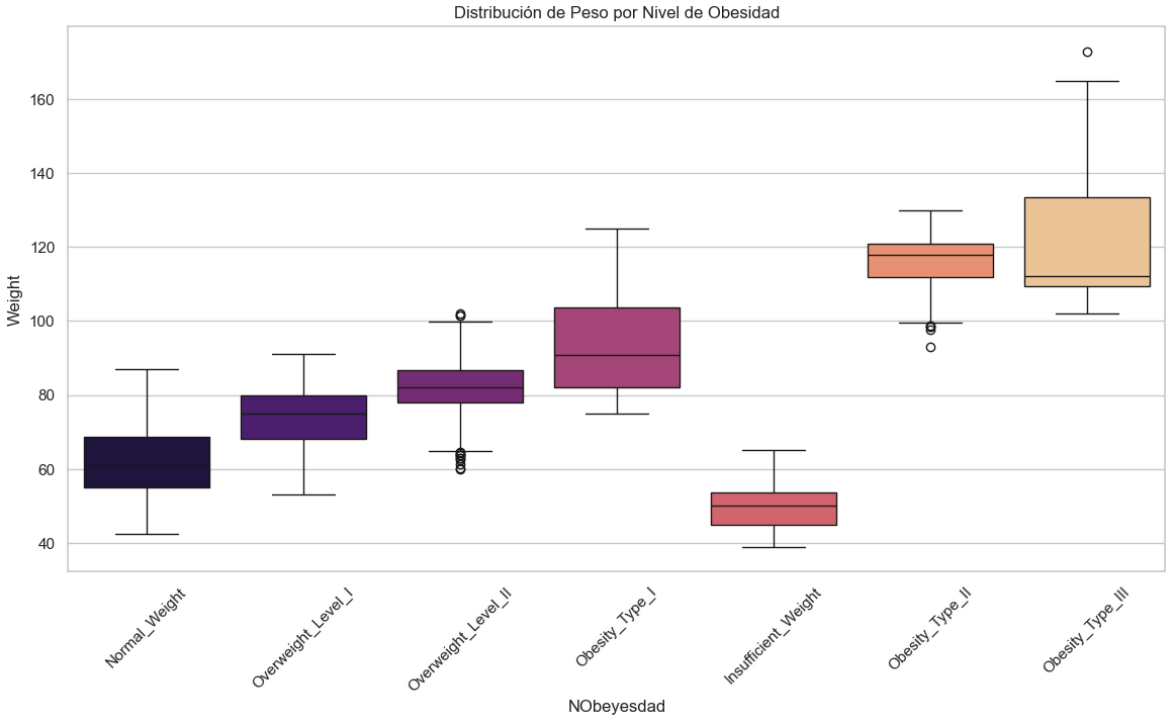

In [13]:
```
plt.figure(figsize=(10, 6))
sns.countplot(data=df, x='family_history_with_overweight', hue='NObeyesdad')
plt.title('Influencia del Historial Familiar por Categoría')
plt.legend(title='Nivel de Obesidad', bbox_to_anchor=(1.05, 1), loc='upper left'
plt.show()
```

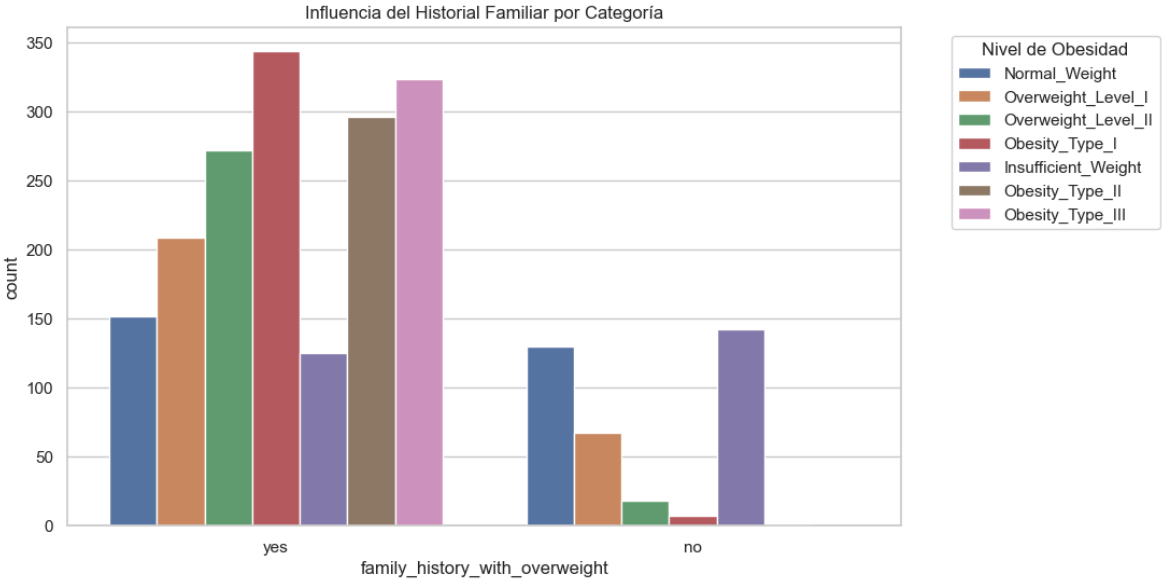

La variable **family_history_with_overweight** es la más influyentes para distinguir entre los grados más altos de obesidad, porque los grados de obesidad altos porque los familiares tienen todos sobrepreso.

In [14]:
```
plt.figure(figsize=(12, 6))
sns.violinplot(data=df, x='NObeyesdad', y='CH2O', palette='coolwarm')
plt.title('Consumo de Agua (CH2O) por Nivel de Obesidad')
plt.xticks(rotation=45)
plt.show()
```

```
C:\Users\gemit\AppData\Local\Temp\ipykernel_9572\1043429327.py:2: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v
0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effe
ct.

  sns.violinplot(data=df, x='NObeyesdad', y='CH2O', palette='coolwarm')
```

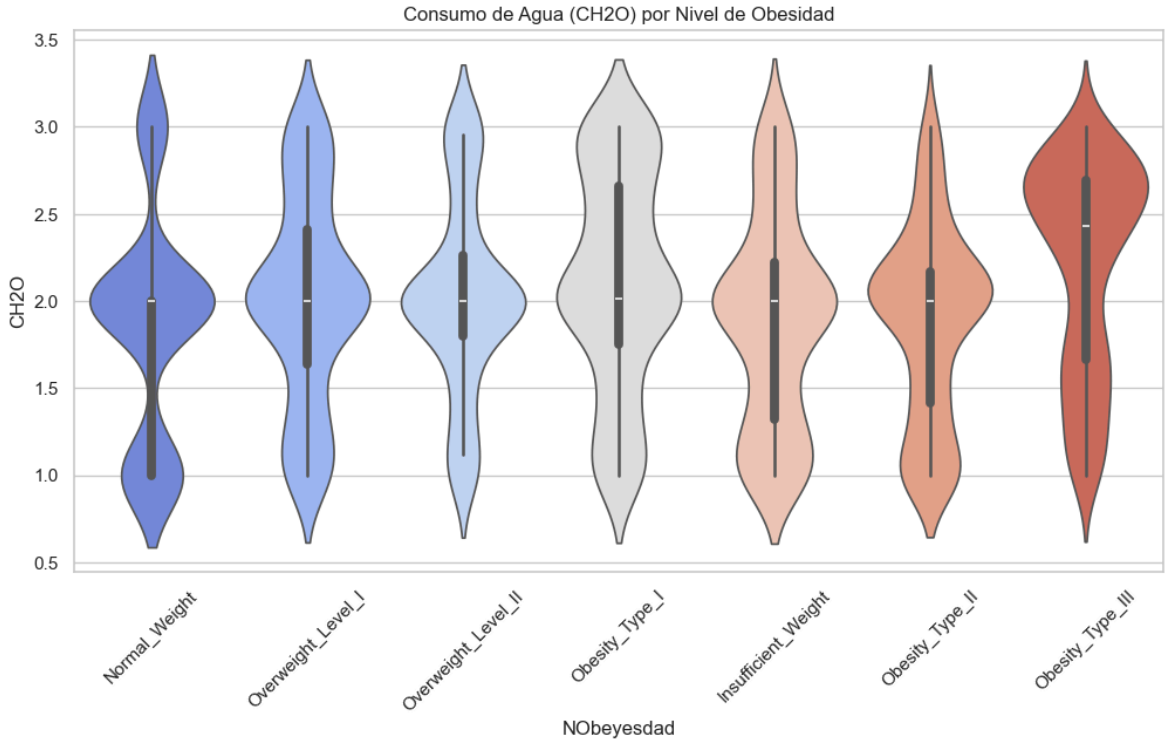

El análisis mediante gráficos de violín revela que el consumo de agua **(CH2O)** tiende a ser superior en las categorías de obesidad severa. Mientras que en el peso insuficiente el consumo modal se sitúa cerca de los 2 litros, en la Obesidad Tipo III se observa una mayor densidad de casos alcanzando los 2.5 - 3 litros.

In [15]:
```
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='Age', y='Weight', hue='NObeyesdad', alpha=0.7)
plt.title('Relación Edad vs Peso por Categoría')
plt.show()
```

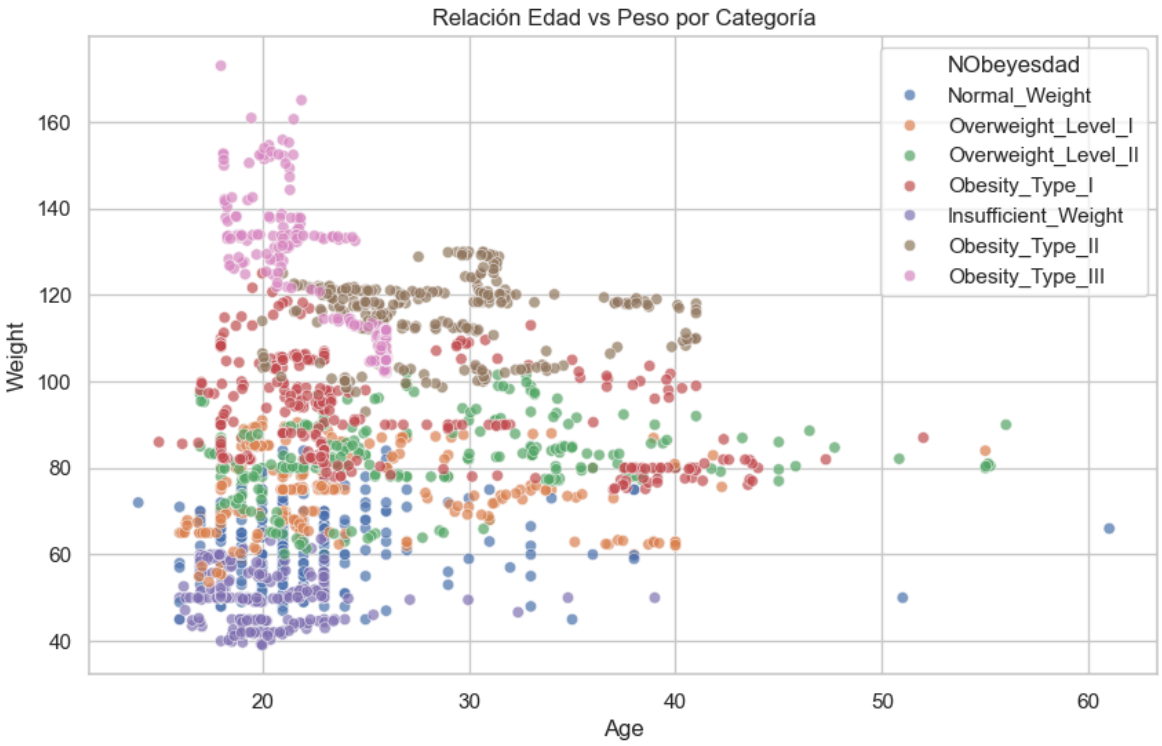

In [16]:
```
# Seleccionamos las variables de interés
interes = df[['CH2O', 'NCP', 'Weight', 'Age',]]
corr_matrix = interes.corr()

# Dibujamos el mapa de calor
plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=True, cmap='Blues', fmt=".2f")
plt.title('¿Qué variables se mueven junto al agua (CH2O)?')
plt.show()
```

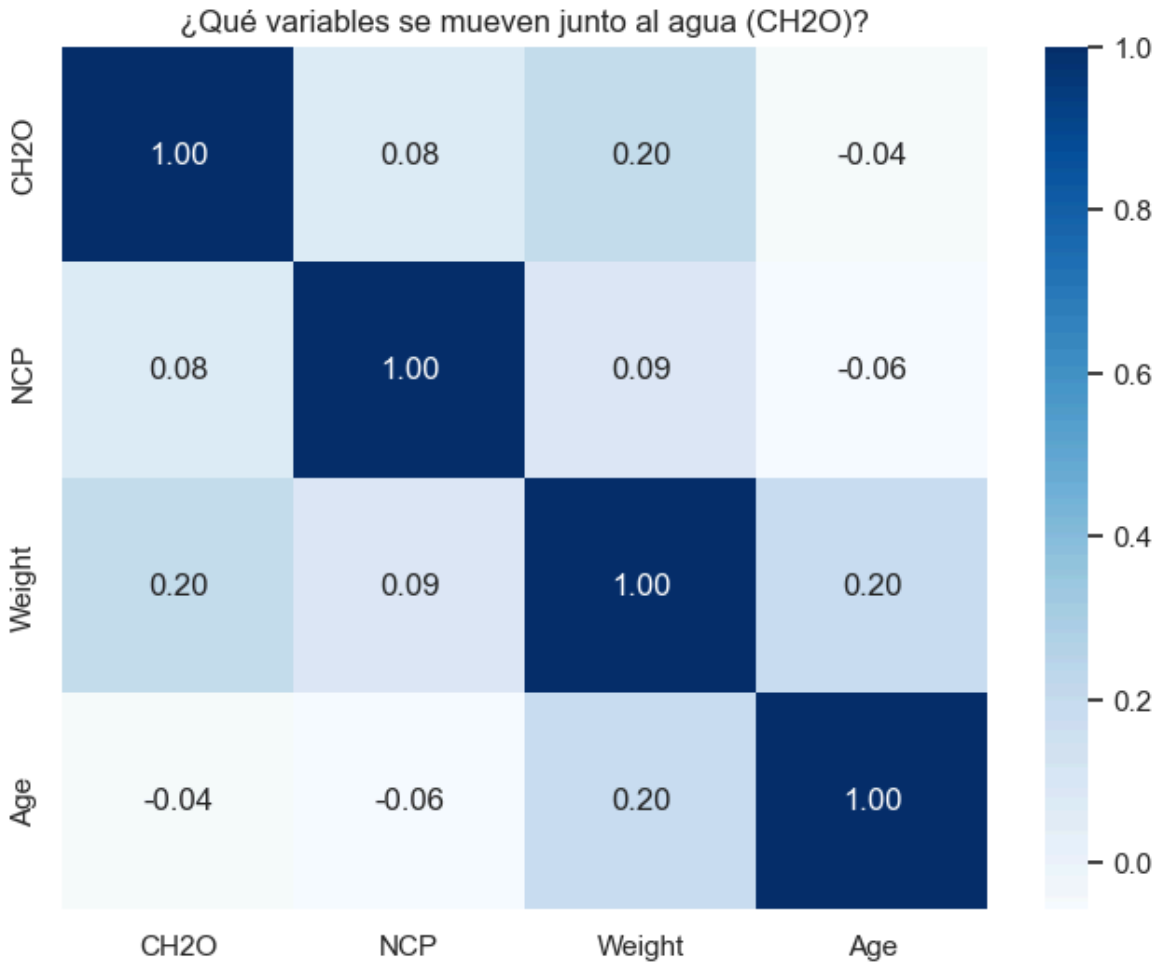

CH2O vs **Weight** (Peso): Aquí vemos un 0.20. Es una relación positiva moderada: las personas con más peso suelen reportar un mayor consumo de agua.

In [17]:
```
# 1. Variables Binarias (Mapeo manual 0/1)
binary_cols = ['Gender', 'family_history_with_overweight', 'FAVC', 'SMOKE', 'SCC
for col in binary_cols:
    # Mapeamos: 'yes' o 'Male' suele ser 1, el resto 0
    if col == 'Gender':
        df[col] = df[col].map({'Male': 1, 'Female': 0})
    else:
        df[col] = df[col].map({'yes': 1, 'no': 0})

# 2. Variables Ordinales (Intensidad 0-3)
# Según tu issue: no:0, Sometimes:1, Frequently:2, Always:3
map_intensidad = {'no': 0, 'Sometimes': 1, 'Frequently': 2, 'Always': 3}
df['CAEC'] = df['CAEC'].map(map_intensidad)
df['CALC'] = df['CALC'].map(map_intensidad)

# 3. Variables Nominales (One-Hot Encoding)
# Esto creará columnas como MTRANS_Public_Transportation, MTRANS_Walking, etc.
df = pd.get_dummies(df, columns=['MTRANS'], prefix='MTRANS')

# 4. Codificación del Target (NObeyesdad)
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
df['NObeyesdad'] = le.fit_transform(df['NObeyesdad'])

df.head(10)
```

Out[17]:

	Gender	Age	Height	Weight	family_history_with_overweight	FAVC	FCVC	NCP	C
0	0	21.0	1.62	64.0	1	0	2.0	3.0	
1	0	21.0	1.52	56.0	1	0	3.0	3.0	
2	1	23.0	1.80	77.0	1	0	2.0	3.0	
3	1	27.0	1.80	87.0	0	0	3.0	3.0	
4	1	22.0	1.78	89.8	0	0	2.0	1.0	
5	1	29.0	1.62	53.0	0	1	2.0	3.0	
6	0	23.0	1.50	55.0	1	1	3.0	3.0	
7	1	22.0	1.64	53.0	0	0	2.0	3.0	
8	1	24.0	1.78	64.0	1	1	3.0	3.0	
9	1	22.0	1.72	68.0	1	1	2.0	3.0	

10 rows × 21 columns

In [18]:

```
# Calculamos la correlación de TODO el dataframe ahora que es numérico
plt.figure(figsize=(16, 10))
full_corr = df.corr()

# Dibujamos el mapa de calor
sns.heatmap(full_corr, annot=True, cmap='RdYlGn', fmt=".2f", linewidths=0.5)
plt.title('Matriz de Correlación Completa: ¿Qué influye más en el Nivel de Obesi
plt.show()
```

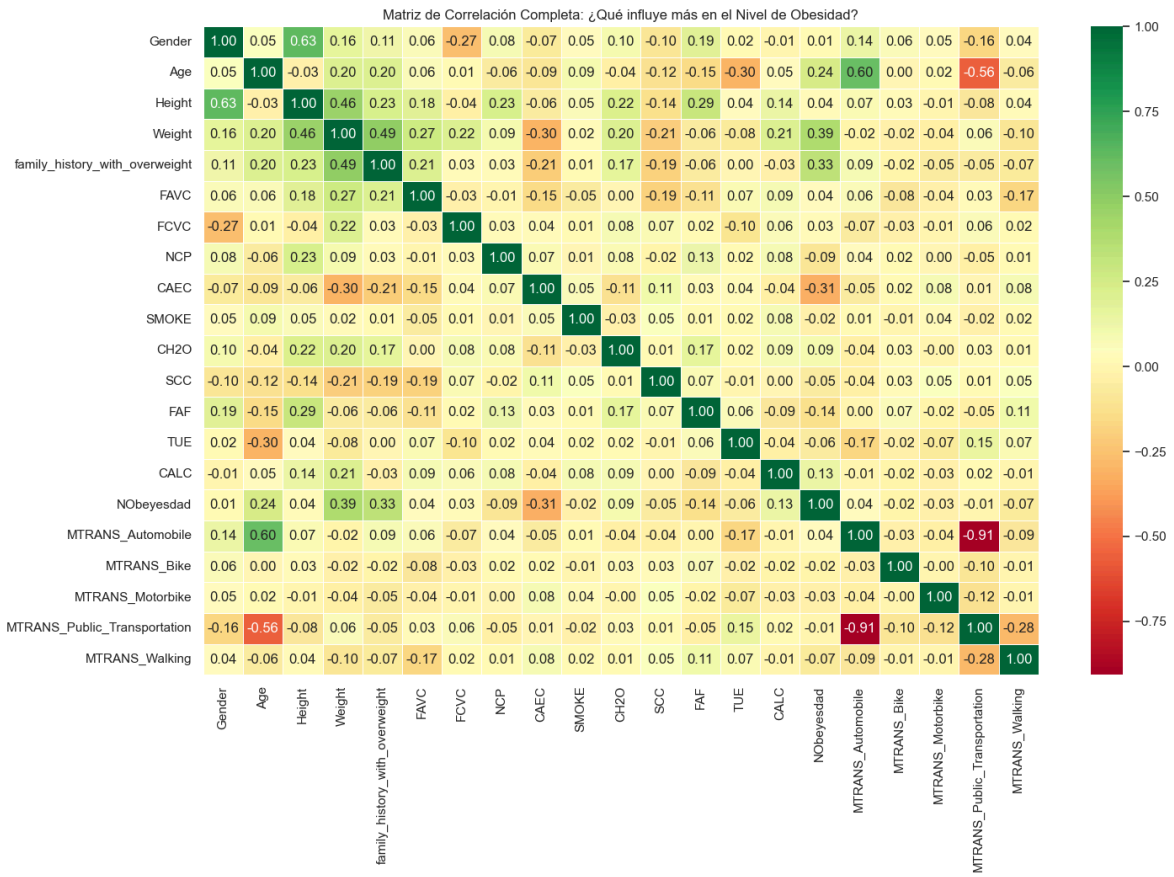

In [19]:
```
# Ver la correspondencia entre los números y las etiquetas originales
dict(zip(le.classes_, le.transform(le.classes_)))
```

Out[19]:
```
{'Insufficient_Weight': np.int64(0),
 'Normal_Weight': np.int64(1),
 'Obesity_Type_I': np.int64(2),
 'Obesity_Type_II': np.int64(3),
 'Obesity_Type_III': np.int64(4),
 'Overweight_Level_I': np.int64(5),
 'Overweight_Level_II': np.int64(6)}
```

In [20]:
```
df.info()
```

```
<class 'pandas.DataFrame'>
Index: 2087 entries, 0 to 2110
Data columns (total 21 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   Gender                          2087 non-null   int64
 1   Age                             2087 non-null   float64
 2   Height                          2087 non-null   float64
 3   Weight                          2087 non-null   float64
 4   family_history_with_overweight  2087 non-null   int64
 5   FAVC                            2087 non-null   int64
 6   FCVC                            2087 non-null   float64
 7   NCP                             2087 non-null   float64
 8   CAEC                            2087 non-null   int64
 9   SMOKE                           2087 non-null   int64
 10  CH2O                            2087 non-null   float64
 11  SCC                             2087 non-null   int64
 12  FAF                             2087 non-null   float64
 13  TUE                             2087 non-null   float64
 14  CALC                            2087 non-null   int64
 15  NObeyesdad                      2087 non-null   int64
 16  MTRANS_Automobile               2087 non-null   bool
 17  MTRANS_Bike                     2087 non-null   bool
 18  MTRANS_Motorbike                2087 non-null   bool
 19  MTRANS_Public_Transportation    2087 non-null   bool
 20  MTRANS_Walking                  2087 non-null   bool
dtypes: bool(5), float64(8), int64(8)
memory usage: 287.4 KB
```

Tras el análisis exhaustivo del dataset sobre niveles de obesidad, se extraen las siguientes conclusiones clave para el desarrollo del modelo predictivo:

Factores Determinantes del Target (NObeyesdad):

- El Peso (Weight) es, como era de esperar, el predictor con mayor correlación positiva (0.39). Sin embargo, al no ser una correlación perfecta, el modelo deberá aprender a combinarlo con otras variables para ser preciso.
- Hábitos Alimenticios: El consumo frecuente de alimentos hipercalóricos (FAVC) muestra una influencia directa y positiva en el aumento del nivel de obesidad.
- Factores Protectores: La actividad física (FAF) presenta una correlación negativa (-0.14), confirmando que niveles más altos de ejercicio se asocian con niveles de obesidad más bajos.

Calidad y Naturaleza de los Datos:

- El dataset es de alta calidad, sin valores nulos, aunque se identifica la presencia de datos sintéticos (decimales en edad y frecuencia de comidas). Esto es beneficioso para el entrenamiento, ya que proporciona una distribución más equilibrada entre las 7 clases de obesidad.
- Existen solapamientos naturales en variables como el peso entre categorías contiguas (ej. Obesidad II y III), lo que justifica el uso de modelos robustos como XGBoost o Random Forest.

In [21]:
```
df.to_csv('../data/processed/obesity_cleaned_g.csv', index=False)
```